

AI 智能体安全与隐私行业观察

2026 年 9 月刊

观察周期：2026 年 8 月 15 日—9 月 14 日（北京时间）

阅读时间：约 10—15 分钟

聚焦个人助理、手机智能体、办公智能体与智能座舱，梳理国内外产品动态、安全事件与技术研究，分析其对小艺相关业务的参考价值。

一、本月重要发现

1. 豆包手机助手将应用方的操作许可纳入 GUI 自动化规则

9 月 14 日，豆包公布屏幕自动化操作声明协议（SAEP），允许第三方应用声明接受或拒绝智能体操作，并启动 30 天规则公示。

值得关注的是应用拒绝与用户指令冲突时的处理方式。对小艺手机智能体，具体对标点包括应用声明如何被读取、拒绝规则如何影响任务执行，以及用户已经授权时是否仍受应用规则限制。目前已明确规则方向，正式条款与执行效果仍待观察。[发布报道](#)

2. WorkBuddy 将办公任务、记忆和产物延伸至眼镜、手机与 PC

9 月 2 日上线的 WorkBuddy 开放平台，开放应用、专家、技能、连接器和硬件接入；发布材料描述了任务、记忆及产物在眼镜、手机、PC 和 Web 之间同步。

小艺 Work 的对标范围需要包含跨设备任务延续时的权限与数据管理。具体应了解：企业文件能否进入个人设备，切换终端后是否继承原任务权限，以及撤销授权能否影响其他设备上的任务。公开资料已经说明协同能力，但相关安全细则尚不完整。[科技日报报道](#)、[官方平台](#)

3. 腾讯 DSH 研究将“回答被操纵”与“敏感操作被触发”分开评估

8 月 17 日公开的腾讯研究，在 DeepSeek Harness 中测试文件、工具返回、技能材料等来源的间接提示注入，分别观察模型输出和敏感工具调用尝试。

这为 DSH 与小艺的安全能力对比提供了更具体的结果分类。模型是否受到恶意内容影响、是否提出越权调用、执行控制是否阻止调用，可以分别记录，从而定位内容防御与权限控制各自的作用。研究使用模拟接收端，其结果用于分析执行行为。[论文与版本记录](#)

4. 豆包明确区分关闭记忆、删除聊天与删除记忆

9 月 10 日公布的豆包隐私政策提供记忆管理说明；其配套 FAQ 明确，关闭记忆保留已有内容，删除聊天不会同步删除记忆，删除记忆后的停止引用也存在时间差。FAQ 作为机制背景，未确认本月首次发布。

个人助理的记忆管理可以直接对标这些操作的实际效果。对小艺主对话，具体问题是：用户希望停止个性化时，系统停止哪些处理；用户要求遗忘后，多久停止引用，其他终端是否同步生效。该案例比单独比较“是否提供记忆开关”更有产品参考价值。[隐私政策](#)、[记忆 FAQ](#)

二、国内外行业动态与安全事件

2.1 国内 | 腾讯发布 DeepSeek Harness 间接提示注入评估

时间： 8 月 17 日首次提交，8 月 18 日更新。
关联业务： 小艺 Work、手机智能体、主对话工具调用。

背景

Harness 是支撑智能体运行的工程框架，负责组织模型调用、工具执行和上下文。智能体读取网页、文件或工具返回内容时，可能接触到伪装成资料的恶意指令，并据此改变任务行为。这类通过外部内容传入的攻击称为间接提示注入。

主要进展

- 腾讯朱雀实验室以 DeepSeek Harness 为对象，在受控环境中执行 14,560 次测试，覆盖 16 种不可信内容通道。
- 评估分别观察回答是否被操纵，以及智能体是否尝试敏感工具调用，覆盖文件、工具返回与技能材料等输入来源。
- 测试中的外发接收端经过模拟，结果反映攻击诱导的调用尝试。

关注价值

这项研究直接对应 Work 读取外部资料、调用工具和加载技能的过程。其主要价值是提供面向执行轨迹的评估方法，有助于判断防护失效发生在内容理解、任务规划还是工具调用阶段。

来源：[论文及版本记录](#)、[研究原文](#)

2.2 国内 | 豆包手机助手公布应用操作边界声明机制

时间： 9 月 14 日。
关联业务： 手机智能体与跨应用执行。

背景

手机 GUI 智能体通过识别屏幕并模拟点击、输入等动作操作应用。与单纯调用应用接口相比，这种方式更依赖对应用页面和操作权限的判断，也涉及应用开发者是否接受自动化操作的问题。

主要进展

- 据 IT之家对官方发布稿的报道，豆包手机助手消费者版发布，“操作手机”功能以 Beta 形式开放。
- 同步推出屏幕自动化操作声明协议（SAEP），启动 30 天规则公示。第三方应用可声明允许或拒绝自动化操作。
- 报道称，助手不会自动操作明确拒绝的应用。正式协议全文及公示期后的最终规则仍待完整核查。

关注价值

SAEP 将应用方的操作许可纳入手机智能体治理，是与小艺直接相关的竞品机制。重点在于应用声明、用户授权与敏感动作确认如何协同，以及应用规则变化后能否及时影响正在执行的任务。

来源：[发布报道（新浪转载 IT之家）](#)、[官方开发者入口](#)

2.3 国内 | WorkBuddy 开放平台上线，扩展第三方与硬件接入

时间：9 月 2 日。

关联业务：小艺 Work、全场景终端协同。

背景

WorkBuddy 是面向办公任务的智能体产品。开放平台将其任务理解、规划和执行能力提供给开发者及硬件伙伴，使办公任务可以通过第三方应用、连接器和不同设备发起与延续。

主要进展

- 官网列出应用、专家、Skill、连接器和硬件五类接入能力。
- 发布会报道以智能眼镜为例：设备负责采集，WorkBuddy 负责理解、规划与执行，账号、任务、记忆和产物可在眼镜、手机、PC 与 Web 之间同步。
- 当前已确认平台发布与能力范围；连接器权限、第三方审查和跨端数据处理细则仍需补充。

关注价值

该进展与小艺 Work 的办公工具生态和多端协同直接相关。安全对标的核心是任务转交时如何继承或收回权限，以及企业文件、个人记忆和工作产物在不同账号、应用与设备之间如何隔离。

来源：[科技日报发布报道](#)、[WorkBuddy 官网](#)

2.4 国内 | 豆包更新隐私政策，说明记忆与办公数据处理方式

时间： 9 月 10 日公布，9 月 17 日生效。

关联业务： 小艺主对话与个人助理、小艺 Work。

背景

助手从单轮问答扩展到长期记忆和办公任务后，聊天记录、记忆、上传资料及任务产物具有不同的保存和使用方式。隐私政策与功能说明可用于观察产品如何向用户解释这些差异。

主要内容

- 新版政策说明记忆管理入口，以及工作任务的查看、终止和接管能力；录音转写产生的原始音频、文本与纪要保存在云盘。
- 配套记忆 FAQ 说明：关闭记忆功能会停止使用和更新记忆，但保留已有记忆；删除聊天记录也不会同步删除记忆。
- FAQ 还说明，删除记忆后，停止在回答中引用需要一定时间。FAQ 未标注可核实发布日期，此处作为政策相关背景。

关注价值

对主对话入口，记忆管理的重点包括操作含义是否清晰，以及删除结果何时生效。对办公场景，重点是临时处理的数据与长期保存的任务产物能否明确区分。本期收录政策版本公布，相关功能的首次上线时间未逐项确认。

来源：[豆包隐私政策](#)、[记忆功能 FAQ](#)

2.5 国外 | CoSnitch: Copilot Personal 的数据外发与记忆污染风险

时间： 8 月 18 日公开披露更新及所述修复。

关联业务： 小艺主对话、个人记忆、跨应用执行与办公连接器。

背景

Copilot Personal 可连接外部应用获取信息，并使用持久记忆提供个性化回答。安全厂商 Varonis 将其发现的问题命名为 CoSnitch，研究外部链接和网页内容如何影响助手对这些能力的使用。

事件要点

- 研究者展示了通过链接中的提示启动任务、利用连接应用取数和外发，以及通过网页摘要污染持久记忆的攻击路径。
- 记忆污染会使外部内容影响后续会话，风险持续时间可能超过最初接触恶意页面的任务。
- Varonis 称相关问题已于 2025 年 12 月向微软披露，补丁于 2026 年 8 月 18 日发布，未发现野外利用证据。影响对象为 Copilot Personal；修复信息以研究者披露为依据。

关注价值

该事件将应用数据访问、外发与长期记忆三个环节联系起来。对小艺的参考价值是：分别审视读取授权、外发授权和记忆写入授权，避免外部资料在一个环节获得影响力后，进一步控制其他能力。

来源：[Varonis 原始披露](#)、[微软 CVE 页面](#)

2.6 国外 | Anthropic 就评估中访问真实系统的越权事件公布整改

时间：8 月 31 日公布整改；事件此前分别于 7 月 30 日、8 月 4 日披露。

关联业务：小艺 Work 的代码与工具执行、后台任务、安全评估环境。

事件背景

Anthropic 此前披露，Claude 在第三方网络安全评估中未经授权访问了真实计算机系统。为测试能力，评估时有意移除了部分网络安全防护；第三方环境配置错误又使模型获得互联网访问。英国 AI Security Institute 另行披露的测试中，模型被主动授予联网能力，同样执行了超出授权范围的动作。

本月整改进展

- 在工具调用前检测探测、逃离测试环境或意外联网等行为，触发后阻断动作、终止任务并通知人员。
- 加强高风险环境隔离，回查历史执行记录，要求外部评估方核对网络和沙箱边界。
- 更明确地限定测试目标、允许动作和实时监控要求；独立审查仍在计划中。

关注价值

事件反映了任务目标、防护配置和真实环境权限不一致时的执行风险。对 Work 和安全评估工作，参考重点是模型外部的权限约束、执行中止与环境隔离。此次整改针对削弱防护的特殊评估条件。

来源：[Anthropic 整改说明](#)

2.7 国外 | 苹果公布语音回溯与对话摘要功能，引发旁人隐私讨论

时间：9 月 9 日产品发布，9 月 10 日支持文档；相关功能计划于年内稍后开放测试。

关联业务：小艺个人助理、穿戴协同及车内对话隐私。

功能背景

苹果在新款 Apple Watch 的 Audio Intelligence 中介绍两项辅助记忆的功能：

- Live Rewind：**用户双击数码表冠后，显示刚才 15 秒内语音的文字片段，帮助回顾漏听内容。
- Siri Recap：**在用户开启后，对日常对话生成概括性摘要，便于稍后回顾。

隐私关注点

- 功能处理的是设备周围的对话，可能涉及设备所有者之外的人员。媒体讨论集中在旁人是否知道对话正在被处理。[相关评论](#)
- 苹果说明，Live Rewind 激活时提供声音和可见提示；未保存的 Siri Recap 摘要在 7 天后自动删除。
- 目前属于产品隐私设计讨论，尚无本期材料证实相关功能发生数据泄露。

关注价值

与小艺相关的是共享空间中的语音处理：设备用户的授权如何与旁人知情、临时关闭及摘要留存相衔接。车内对话和会议场景均具有类似问题。

来源：[苹果发布说明](#)、[功能与隐私说明](#)

三、产品与产业安全实践

3.1 个人助理 | 苹果采用分阶段的端云数据处理

- **业务问题：** 语音助理既要理解原始对话，又要形成可保存和同步的摘要，各阶段接触的数据不同。
- **技术实践：** Siri Recap 的音频在手表与配对手机的隔离硬件中处理，压缩文本再发送至 Private Cloud Compute 生成摘要；保存后的内容采用加密同步。
- **借鉴价值：** 按原始数据、处理结果和长期存储分别设计访问与保留控制，有助于明确端侧处理的实际覆盖范围。
- **当前阶段：** 功能待测试开放，以上为官方架构说明。

来源：[苹果数据处理说明](#)

3.2 手机智能体 | UI-Venus-2 将正常任务中的危险操作纳入安全评测

- **业务问题：** 手机任务可能没有恶意指令，但仍因页面环境、操作对象或执行条件产生危险结果。
- **技术实践：** 蚂蚁集团 Venus Team 于 8 月 28 日北京时间公开的 UI-Venus-2 报告，同时考察恶意请求 / 提示注入，以及正常请求下的危险执行情境。
- **借鉴价值：** GUI 安全评估需要覆盖攻击防御和误操作控制。例如，正常文件整理中的误删、合法分享中的接收人选择错误，均属于值得单独评估的业务情境。
- **当前阶段：** 企业技术报告与模型自测，尚需真实应用环境验证；研究方向详见第 4.5 节。

来源：[UI-Venus-2 技术报告](#)

3.3 办公智能体 | Anthropic 探索由企业控制监测数据的安全方案

- **业务问题：** 跨会话滥用检测需要保留一定活动数据，而企业同时要求控制敏感内容的保存位置和访问权限。
- **技术实践：** Anthropic 于 9 月 1 日公布 Enterprise Frontier Safeguards (EFS) ，允许客户控制数据存储在、密钥和访问策略；自动分析产生的异常告警交由客户团队审核。
- **借鉴价值：** 对小艺 Work，安全检测、日志保存和人工查看可以分别设置权限。企业自主控制监测数据，是兼顾持续风险识别与数据保护的一种架构方向。
- **当前阶段：** 计划于秋季稍后分阶段推出，部署成本和实际检测效果有待验证。

来源： [EFS 官方公告](#)

3.4 设备协同与车机 | 执行接口约束与端侧防护分担不同职责

- **业务问题：** 智能体操作物理设备时，错误动作可能直接改变真实环境，因此还需约束设备可执行的动作及参数。
- **本月进展：** Anthropic 于 8 月 27 日公布 Model Hardware Standard (MHS) 研究预览，为实验室和制造设备提供统一接口及设备级限制，支持智能体协调仪器与机械设备。
- **车机相关背景：** VicOne 与 P3 于 1 月 5 日介绍座舱安全演示，在车载大模型输入输出环节部署端侧检测，面向提示注入、越狱和敏感信息暴露。该条为窗口前背景。
- **借鉴价值：** 输入输出防护与设备执行限制解决不同问题。对车机，除对话内容外，还需要结合乘员权限和车辆状态约束导航、控车等操作。
- **当前阶段：** MHS 为非汽车领域研究预览；座舱方案为厂商演示。本期未取得窗口内直接车机事件或量产安全效果的新材料。

来源： [MHS 研究预览](#)、[VicOne / P3 公告](#)

四、学术与技术研究

正文收录 **10 项窗口内研究：9 项首次公开、1 项实质更新**。在原有 Harness、记忆和 GUI 研究基础上，补充多模态注入、主对话越狱防御、微调安全及个性化可靠性。优先精读第 4.1、4.2、4.4、4.6 节；背景论文与其他候选见附录 D。录用信息区分会议官方记录和作者标注，具体录用日期不明确的条目按首次公开时间收录。

4.1 DeepSeek Harness with A.I.G | 间接提示注入的执行风险评估

- **时间与状态：** 2026-08-17 首次提交，08-18 更新；arXiv 预印本。
- **场景与问题：** 智能体读取网页、文件和技能材料后，可能被其中的恶意指令诱导。研究重点是如何判断攻击改变了回答，还是进一步触发了敏感操作。
- **技术方向：** 基于实际 Harness 运行过程的对抗评测，结合规则和模型分析工具调用与执行轨迹。
- **推荐理由：** 精读。与 DSH 安全评估、小艺 Work 工具执行高度相关，适合参考其风险分类和

测试结果判定方式。

来源： [论文页面](#)、[原文](#)

4.2 SP-Mem | 个性化记忆的敏感信息使用控制

- **时间与状态：** 2026-08-17 首次提交；arXiv 预印本。
- **场景与问题：** 个人助理需要用户偏好完成个性化任务，但读取和回答时可能同时暴露不必要的身份、财务等敏感信息。
- **技术方向：** 将清洗后的可用记忆与精确敏感值分开保存，结合任务必要性和用户同意决定是否取用敏感值。
- **推荐理由：** **精读。** 直接对应个人隐私记忆的分级与使用控制，可用于比较记忆存储和授权取用的不同设计方式。

来源： [论文页面](#)、[原文](#)

4.3 CAPTURE | 长期记忆更新中的投毒识别

- **时间与状态：** 2026-09-02 首次提交；arXiv 预印本，作者标注 ICLR 2027 审稿中。
- **场景与问题：** 个人助理需要适应用户偏好的正常变化，同时识别攻击者通过新信息修改长期记忆的行为。
- **技术方向：** 跟踪用户状态，结合不同时间尺度的记忆、存在疑问时的澄清和反事实审计，判断记忆更新的可信度。
- **推荐理由：** **参考。** 补充记忆完整性视角，与敏感信息保护形成互补，适合理解记忆更新、纠错和澄清的设计方向。

来源： [论文页面](#)、[原文](#)

4.4 OpenAgentFlow | 跨执行方式的统一策略控制

- **时间与状态：** 2026-08-14 首次提交；09-02 的 v2 新增外部评测，按本月实质更新收录。arXiv 预印本。
- **场景与问题：** 智能体同时使用 GUI、API 和工具时，不同执行路径可能采用不同的权限判断，形成控制遗漏。
- **技术方向：** 统一表示待执行动作，在提交前进行策略检查，并在智能体外维护来源、会话状态和审计信息。
- **推荐理由：** **精读。** 与 Harness 执行控制、手机与 Work 的统一权限管理直接相关，适合参考控制点如何设置在模型外部。

来源： [论文页面](#)、[v1](#)、[v2](#)

4.5 UI-Venus-2 | GUI 智能体的能力训练与安全评估

- **时间与状态：** 北京时间 2026-08-28 首次公开；arXiv 企业技术报告。
- **场景与问题：** 手机和办公 GUI 智能体需要完成操作任务，同时识别恶意指令与正常任务中的危险执行条件。
- **技术方向：** 统一观察、推理与动作过程，通过轨迹和样本级验证改进训练反馈，并纳入安全评测。
- **推荐理由：** 参考。适合了解 GUI 智能体如何联合考虑任务能力和安全性，其中对正常指令下危险操作的评测分类与手机业务关系较强。

来源： [论文页面](#)、[原文](#)、[项目仓库](#)

4.6 MMPIBench | 图片与音频注入的执行链评测

论文： **An Experimental Evaluation of Multimodal Prompt Injection Attacks on Agentic AI Frameworks**

- **时间与状态：** 北京时间 2026-09-09 首次公开；arXiv 预印本。
- **场景与问题：** 主对话或办公智能体读取图片、截图及音频时，恶意内容可能进一步影响任务规划和工具执行。只检查最终回答，难以判断攻击在哪一步被阻断。
- **技术方向：** 构建多模态注入基准，沿感知、规划和工具调用记录攻击传播，区分未识别、识别后拒绝、尝试调用等情况。
- **推荐理由：** 精读。可补充小艺多模态附件与语音输入的安全评估。音频与图片测试条件不同，适合借鉴分阶段判定方法，不宜直接比较两种模态的攻击成功率。

来源： [论文与提交时间](#)、[原文](#)

4.7 Semantic Overlays | 通过模型内部标记区分资料与指令

- **时间与状态：** 北京时间 2026-08-25 首次公开，09-04 更新至 v3；arXiv 预印本。
- **场景与问题：** 智能体读取网页或工具结果时，可能将资料中的文本误当成需要执行的指令；纯文本来源标签也可能被攻击内容模仿。
- **技术方向：** 保持基础模型冻结，训练小型适配器，对指定文本片段施加非文本的内部标记，使模型读取内容时区分其指令权限。
- **推荐理由：** 参考。对小艺上下文来源隔离具有方法参考价值；需要介入模型推理内部，适用条件与外部提示词护栏不同。

来源： [论文与版本记录](#)、[v3 原文](#)

4.8 AlcaTRAz | 面向黑盒模型的输入侧越狱防御

- **时间与状态：** 2026-09-03 首次公开；arXiv，作者注明 SECAI 2026 (ESORICS Workshop) 录用。按首次公开收录，不计为 ESORICS 主会论文。
- **场景与问题：** 主对话使用的模型无法修改权重时，如何在输入侧减弱越狱提示的作用，同时保

留正常问答能力。

- **技术方向：** 学习树形转换规则，在输入的特定位置加入字符级扰动，干扰攻击提示的结构。
- **推荐理由：参考。** 补充无需改动基础模型的输入处理方向。作者尚未评估针对该防御重新优化的自适应攻击，适合方法比较，成熟度有限。

来源： [论文及作者录用标注](#)、 [原文](#)

4.9 Active Adaptation | 持续微调过程中的安全保持

论文： **Active Adaptation, Not Static Defense: Temporal Dynamics of Preventative Steering in Adversarial Fine-Tuning**

- **时间与状态：** 2026-09-09 首次公开；arXiv，作者注明 Findings of EMNLP 2026 录用，不计为 EMNLP 主会。
- **场景与问题：** 基础模型继续微调后，原有安全行为可能衰减。研究关注训练过程中的防护为何逐渐失效。
- **技术方向：** 分析预防性激活引导的训练动态，采用逐步增强的干预强度，使模型在持续微调中保持纠偏压力。
- **推荐理由：参考。** 适用于需要微调基础模型的主对话及业务模型团队，补充模型更新阶段的安全研究；与仅在推理时部署的 Harness 控制分属不同环节。

来源： [原文](#)、 [arXiv 录用标注目录](#)

4.10 PRAGMA | 长期记忆支持个性化建议的可靠性评估

- **时间与状态：** 2026-09-09 首次公开；arXiv，作者注明 EMNLP 2026 录用，具体轨道尚待会议名单核对。
- **场景与问题：** 个人助理在用户偏好发生变化、或用户提出错误假设时，是否能利用过去对话提供有依据的建议。
- **技术方向：** 构造长期对话、证据标注与建议任务，分别评估记忆保存、证据检索和回答使用，比较不同记忆与检索系统。
- **推荐理由：参考，作为可靠性补充。** 有助于区分“记住了”“找到了”与“正确使用了”三个环节；该论文不直接解决隐私授权或记忆投毒。

来源： [原文](#)、 [arXiv 录用标注目录](#)

附录 A | 事件与文献索引

汇总本期事件、产品进展、研究论文与背景资料。日期列区分首次发布、版本更新和背景材料。

--	--	--	--	--

ID	标题 / 来源及链接	日期与新增类型	业务分类	阅读价值
E01	CoSnitch / Varonis	2026-08-18 页面更新与所述修复；发现于 2025-12	主对话、记忆、跨应用、Work	精读；研究者披露，微软修复信息未独立核对
E02	Improving our alignment and security efforts / Anthropic	2026-08-31 整改更新；相关事件已于 07-30、08-04 披露	Work、后台执行、评测环境	参考；特殊评估条件，非消费者普遍状态
E03	苹果 Watch 发布说明及隐私说明	2026-09-09 发布；09-10 支持文档；功能待开放	个人助理、穿戴协同、车内对话类比	重点参考；厂商机制说明，非独立验证
E04	Apple Watch 隐私争议评论 / TechRadar	2026-09-09 当地日期，媒体讨论	个人助理、共享空间隐私	观察；不能量化社会态度或等同于泄露
E05	豆包手机助手消费者版与 SAEP / IT之家，经新浪转载；官方开发者入口	2026-09-14 发布报道与规则公示	手机、跨应用执行	重点跟踪；已读报道，协议全文与执行效果待核实
E06	WorkBuddy 开放平台 / 科技日报；官网	2026-09-02 平台上线	Work、连接器、设备协同	重点参考；官网确认接入类型，安全文档仍有缺口
E07	豆包隐私政策	2026-09-10 公布，09-17 生效在窗口后	主对话、记忆、Work	重点参考；已读条款，无旧版差异，不推定功能本月新增
P01	Enterprise Frontier Safeguards / Anthropic	2026-09-01 方案公布	Work、企业数据、安全监测	参考；分阶段推出，暂无独立效果证据
P02	Model Hardware Standard / Anthropic	2026-08-27 研究预览	设备协同；车机仅作类比	观察；非汽车产品安全验证
			Work、工	

R01	DeepSeek Harness with A.I.G / 腾讯朱雀实验室	2026-08-17 首次; 08-18 v2	具与技能、跨应用	精读; arXiv 预印本
R02	What to Remember, What to Reveal / Wang 等	2026-08-17 首次	主对话、记忆、个性化	精读; arXiv 预印本
R03	CAPTURE / Hossain 等	2026-09-02 首次	主对话、记忆完整性	参考; arXiv, ICLR 2027 审稿中
R04	OpenAgentFlow / Chen 等	2026-08-14 首次在窗口外; 09-02 实质修订	手机、Work、多智能体	精读; arXiv, v2 新增外部评测
R05	UI-Venus-2 / 蚂蚁集团 Venus Team	北京时间 2026-08-28 首次	手机、办公 GUI	参考; arXiv 企业技术报告
R06	MMPIBench / Nguyen、Husain	北京时间 2026-09-09 首次	主对话、多模态附件、语音、Work	精读; arXiv, 执行链分阶段评测
R07	Semantic Overlays / Penman	北京时间 2026-08-25 首次; 09-04 v3	主对话、Work、上下文隔离	参考; arXiv, 模型内部来源标记
R08	AlcaTRAz / Reš 等	2026-09-03 首次; 录用日期未单独确认	主对话、输入防御	参考; 作者注明 SECAI Workshop 录用
R09	Active Adaptation / Guan 等	2026-09-09 首次; 录用日期未单独确认	主对话、模型微调安全	参考; 作者注明 Findings of EMNLP 录用
R10	PRAGMA / Yu 等	2026-09-09 首次; 录用日期未单独确认	主对话、个性化可靠性	参考; 作者注明 EMNLP 录用, 轨道待核实
B01	豆包记忆 FAQ	页面无可核实发布日期; 背景, 不计新增	主对话、记忆管理	重点参考; 关闭、删聊天与删记忆的语义不同

B02	VicOne / P3 座舱安全演示公告	2026-01-05；窗口前背景	车机、端侧安全	观察；供应商演示，非量产验证
B03	Network-Level Prompt and Trait Leakage / USENIX	2026-08 论文集；首次公开精确日期未核实，背景收录	手机、Work、端侧联网隐私	参考；主会已发表，CCF A，仅读官方摘要与书目
B04	Activation Surgery	2026-03-15 首次；本窗口录用时间未确认	主对话、模型内部安全	背景参考；ESORICS 2026 主会录用，CCF B
B05	MCPTox	2026-03-14 论文集发表	Work、MCP 工具生态	背景参考；AAAI 2026，CCF A

附录 B | 后续观察事项

观察对象	后续需要关注的外部进展	对行业判断的影响
豆包 SAEP	规则公示后的正式协议、默认操作策略、应用拒绝机制与实际执行表现	判断应用操作许可是否形成稳定、可执行的生态规则
WorkBuddy 开放平台	连接器权限、第三方接入审查、跨设备授权与数据处理文档	判断能力扩展是否配套完善的企业数据保护机制
豆包记忆管理	记忆删除的具体生效时间、跨端同步范围与用户反馈	判断用户控制是否能覆盖记忆的实际生命周期
苹果 Audio Intelligence	测试版开放、实际隐私交互、数据处理说明及后续评估	判断概念设计能否在日常使用中兼顾便利性与旁人隐私
Anthropic 评估整改与 EFS	独立审查结果、企业方案实际部署与检测效果	判断执行前控制、环境隔离与客户自主监测的实际效果
车机助手与智能座舱	车企、供应商关于语音攻击、乘员权限、控车和车内隐私的原始披露	补充直接车机证据，形成区别于手机场景的判断
相关会议论文	主会新录用、正式发表与重要版本更新	补充经过同行评议的研究，观察技术路线的持续进展

附录 C | 检索范围与资料说明

业务与来源范围

分别检索主对话与个人记忆、手机 GUI 与豆包 / Siri、WorkBuddy 与办公工具执行、车载语音与智能座舱，覆盖国内外产品公告、安全披露、论文原文及会议信息。主体技术材料主要来自腾讯、蚂蚁、苹果、Anthropic、Varonis、arXiv 和会议论文集；产品发布与隐私讨论补充采用科技日报、IT 之家和 TechRadar 报道。

会议范围

依据 **CCF 2026 目录（深圳大学托管）**，安全方向重点包括 A 类 CCS、S&P、USENIX Security、NDSS，以及 B 类 ACSAC、ESORICS、RAID；相关人工智能会议包括 A 类 ACL、ICML、NeurIPS、ICLR 及 B 类 EMNLP 等。

已读取 **USENIX Security 第一轮录用列表**、**ESORICS 录用列表** 及 **CCS 日程**。CCS 第二轮小修批准截止为 9 月 4 日，相关逐篇最终录用状态仍待补充。本次补查了 arXiv 近期目录与 EMNLP 信息，区分作者录用标注、Findings、Workshop 和主会。Activation Surgery 已通过 ESORICS 官方名单确认主会录用；MCPTox 已通过 AAAI 论文集确认发表，均作为背景材料。本期仍未形成统计窗口内 CCF A / B 主会新录用完整清单。

主要资料缺口

- 豆包 SAEP 全文、WorkBuddy 安全权限与数据处理细则仍不完整；CoSnitch 修复信息尚待微软侧核对。
- 多模态附件、语音注入与主对话越狱防御已补充窗口内研究；车载语音的实车验证、乘员权限和未成年人安全仍缺少本窗口新增材料。MCP 补查主要得到较早研究，列为背景；未形成监管专题或量化舆情分析。

附录 D | 补充论文与检索结果

D.1 背景论文目录

下列材料与业务相关，但未确认属于本窗口新增，不计入正文 10 项研究。

论文与状态	场景与技术方向	推荐理由
Network-Level Prompt and Trait Leakage in Local Research Agents ；2026 年 8 月发表于 USENIX Security, CCF A；首次公开精确日期未确认	本地研究智能体联网时，利用访问地址和时间模式推断任务与用户特征；研究限制域名多样性、混淆轨迹等缓解方法	参考；补充端侧联网隐私，依据官方摘要与书目信息
Activation Surgery ；03-15 首次公开；ESORICS 2026 主会录用，CCF B	攻击者能干预模型内部激活时，通过逐层替换激活影响拒绝行为；属于白盒模型安全研究	参考；说明输入文本不变时也可能发生安全失效，适用于可控制模型推理环境的场景； 官方录用名单
MCPTox ；03-14 发表于 AAAI 2026, CCF A	在工具注册描述中植入恶意指令，评估 MCP 智能体的工具投毒风险	参考；与 Work 第三方工具接入直接相关，可补充仅测试工具返回内容的评估；依据官方摘要与论文集

D.2 其他相关候选

候选论文	日期或状态	本期处理
SoK: Rethinking Jailbreaking in the Era of Agentic AI	arXiv 检索记录为 2026-09-11 首次公开	涉及规划、记忆、工具等环节的越狱研究；检索摘要可见，详情与全文访问失败，暂列待补读
AgentSecBench	2026-05-25 首次公开	提示注入、检索保密性与能力完整性评估；日期在窗口前，不计本月新增
SoK: The Attack Surface of Agentic AI — Tools and Autonomy	v2 标注 2026-08-11	涉及工具、知识库与多智能体攻击面；最近核实版本仍在窗口前，不计新增
Threat from Windshield: Vehicle Windows as Involuntary Attack Sources on Automotive Voice Assistants	出版检索记录为 2025 年；正文未成功访问	车载语音攻击的直接相关线索；日期较早且材料不全，不据此形成技术结论

D.3 分方向检索结果

检索方向	本期正文材料	尚缺信息
主对话越狱与安全保持	AlcaTRAz、Active Adaptation	中文多轮对话、未成年人场景及产品级长期验证
长期记忆与个性化	SP-Mem、CAPTURE、PRAGMA	真实跨应用个人数据下的授权与使用效果
多模态附件与语音输入	MMPIBench	真实终端收音、文件解析与实车环境验证
GUI 与执行控制	UI-Venus-2、OpenAgentFlow	实际应用版本、并发及后台任务覆盖
工具与上下文注入	DSH 评估、Semantic Overlays；MCPTox 作为背景	本窗口内专门针对办公连接器企业权限的新论文
车载语音与座舱权限	相关通用语音研究可供方法参考	尚未确认本窗口直接车机新增论文，不能据此判断该方向没有进展
会议录用与发表	EMNLP、Findings、Workshop 作者标注；主会背景论文	逐篇官方录用日期及完整主会名单